Einführung in den Compilerbau Einleitung



WS 2018/19

Andreas Koch

FG Eingebettete Systeme und ihre Anwendungen Informatik, TU Darmstadt



Compiler



- Schnittstelle zwischen
 - Programmiersprache
 - Maschine

Programmiersprache Gut für Menschen handhabbar

- Smalltalk
- Java
- C++

Maschine Getrimmt auf

- Ausführungsgeschwindigkeit
- Preis/Chip-Fläche
- Energieverbrauch
- Nur selten: Leichte Programmierbarkeit



Auswirkung von Compilern



Entscheidet über dem Benutzer zugängliche Rechenleistung

Beispiel: Bildkompression auf Dothan CPU, 2 GHz

Compiler	Ausführungszeit	Programmgröße
GCC 3.3.6	7,5 ms	13 KB
ICC 9.0	6,5 ms	511 KB



Programmiersprachen



Hohe Ebene: Smalltalk, Java, C++ Mittlere Ebene: Assembler

Niedrige Ebene:

Maschinensprache

var i : Integer;

LOAD R1, (i) LOADI R2, 1

R1, R1, R2

i := i + 1:

Unterschiedliche Abstraktionsebenen



- Auf unteren Ebenen immer feinere Beschreibung
- Immer näher an Zielmaschine (Hardware)
- Details werden von Compiler hinzugefügt
 - Durch verschiedenste Algorithmen
 - Analyse von Programmeigenschaften
 - Verfeinerung der Beschreibung durch Synthese von Details



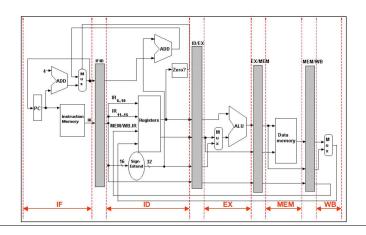


Auswirkungen der Zielmaschine



Einfach: Hennessy & Patterson DLX

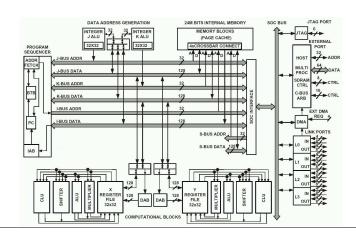






Komplizierter: Analog Devices TigerSHARC



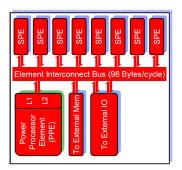




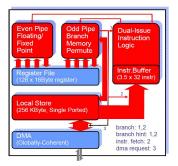
Problematisch: IBM/Sony Cell Processor



Übersicht



SPE





Spezialisierte Anforderungen an CPUs



Je nach Anwendungsgebiet mehr oder weniger wichtig ...

- Rechenleistung (hoch/niedrig)
- Datentypen (Gleitkomma, ganzzahlig, Vektoren)
- Operationen (Multiplikationen, MACs)
- Speicherbandbreite (parallele Speicherzugriffe)
- Energieeffizienz
- Platzbedarf (für den Prozessorchip)

...können häufig nur durch spezialisierte Prozessoren erfüllt werden

⇒Benötigen passende Compiler



Königsklasse: Paralleles Rechnen



DOI:10.1145/1461928.1461946

Research and education in compiler technology is more important than ever.

BY MARY HALL, DAVID PADUA, AND KESHAV PINGALI

Compiler Research: The Next 50 Years

Communications of the Association for Computing Machinery (CACM), Februar 2009



Technologie



- Taktfrequenz von Prozessoren nur mit Mühe steigerbar
- Trend weg von hochgetakteten Einzelprozessoren
- ...hin zu vielen (aber langsameren) Prozessoren
- Wie parallele Strukturen programmieren?
- Erste praktische Ansätze
 - OpenMP: Mehr-Kern-CPUs
 - NVidia CUDA: GPUs
 - OpenCL: Heterogene Systeme (GPUs+CPUs, experimentell auch schon FPGAs)
- Aber noch wenig abstrakt
- Keine automatische Parallelisierung!



Motivation: Compilerbau in der Lehre



Kombination von verschiedenen Feldern der Informatik

- ► Theoretische Informatik (Parsing)
- Technische Informatik (Architektur der Zielmaschine)
- Praktische Informatik (Software-Engineering beim Aufbau des Compilers)

⇒Programmieraufgaben betreffen alle Felder!



Motivation: Compilerbau im Beruf



Apple Compu	ıter				
Job Title	Sr Compiler Engineer				
Posting Date	1/30/2006				
Job Location	Siemens				
Description	Job Title Principal Compiler Engineer				
	Posting Date Sony Computer Entertainment				
	Job Location				
	Description	Job Title	Compiler Engineer		
		Posting Date	RWTH Univer	sity	
		Job Location			
		Description	Job Title	Research assistant/PhD candidate	
			Posting Date	11/15/2005	
			Job Location	Aachen, Germany	
			Description	The SSS division performs research and development on electronic design automation tools for embedded systems, e.g. future telecommunication and multimedia systems. Major research areas include compilers for	



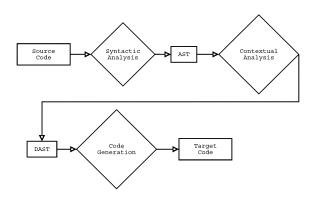


Aufbau von Compilern



Vorgehen: Bearbeitung in mehreren Phasen





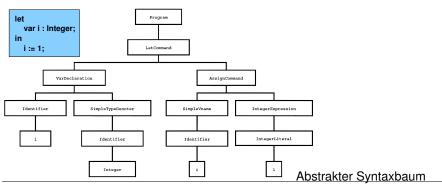
Zwischendarstellung(en) für den Informationsaustausch



Syntaxanalyse



- Überprüfung ob Programm Syntaxregeln gehorcht
- Speichern des Programmes in geeigneter Darstellung

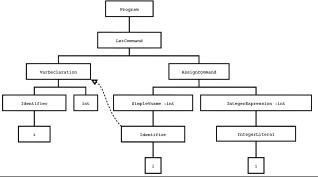




Kontextanalyse - Identifikation



- Ordne Variablen ihren Deklarationen zu
- Berechne Typen von Ausdrücken



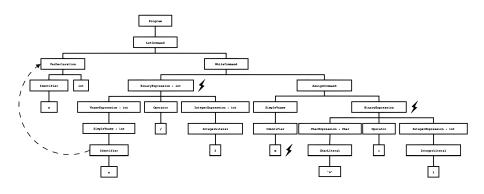
DAST: Dekorierter bzw. annotierter AST



Kontextanalyse - Überprüfung



Erkenne Fehler in Variablen- und Typzuordnung





Code-Erzeugung 1

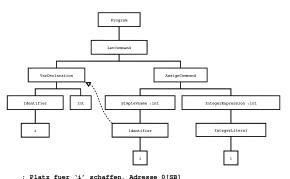


- Programm ist syntaktisch und kontextuell korrekt
- Übersetzung in Zielsprache
 - Maschinensprache
 - Assembler
 - **C**
 - Andere Hochsprache
- Ordne DAST-Teilen Instruktionen der Zielsprache zu
- Handhabung von Variablen
 - 1. Deklaration: Reserviere Speicherplatz für eine Variable
 - 2. Verwendung: Referenziere immer den zugeordneten Speicherplatz



Code-Erzeugung 2





- 0: PUSH 1: LOADL

- STORE (1) 0[SB] POP (0)
- HALT

- ; Wert 1 auf Stack legen
- : ein Datenwort vom Stack nach Adresse 0[SB] schreiben
- ; Platz von 'i' wieder aufgeben
- : Ausfuehrung beenden





Optimierung



Optimierender Compiler





- Front-End: Syntaktische/kontextuelle Analyse
- Back-End: Code-Erzeugung
- Middle-End: Transformation von Zwischendarstellungen
 - Intermediate Representation (IR)
 - Keine direkte Code-Erzeugung aus Front-End IR
 - Verwendet in der Regel zusätzliche interne Darstellungen

Ziel: Verbesserung des erzeugten Codes in Bezug auf bestimmte Gütemaße



Beispiele für Optimierung



Constant-Folding

$$x = (2+3) * y$$

$$x = 5*y$$

int t = 0;

Common-Subexpression Elimination

```
x = 5 * a + b; t = 5 * a; x = t + b; y = 5 * a + c; y = t + c;
```

Strength Reduction

for (i=0; i <= j; ++i) {

a[i*3] = 42;

```
for (i=0; i <= j; ++i) {
   a[t] = 42;
   t = t + 3;
}</pre>
```

Loop-invariant Code Motion

```
int t;
for (i=0; i <= j; ++i) {
   t = x * y;
   a[i] = t * i;</pre>
```





Organisatorisches



Studienleistung



Wechsel auf anderen Foliensatz...



Material: Grundlage der Vorlesung



Grundlagen von Compilern: Fast vollständig

Programming Language Processors in Java von David Watt und Deryck Brown, Prentice-Hall 2000

Auszugsweise noch weiteres Material, z.B. zum ANTLR Parsergenerator.



Übersichtswerk



Guter allgemeiner Überblick, aber im Detail mit anderen Schwerpunkten als bei uns

Compilers, 2. Auflage (!)

von Aho, Sethi, Ullmann, Lam, Addison-Wesley 2006

Auch auf Deutsch verfügbar



Aufbau der Veranstaltung 1



Überblick über Front-End¹ (ca. 3 Wochen)

- Lexing/Parsing
- Zwischendarstellungen

Überblick über Middle-End¹ (ca. 2 Wochen)

Semantische / Kontextanalyse

Überblick über Back-End¹ (ca. 4 Wochen)

- Laufzeitorganisation
- Code-Erzeugung

- IMT3052 von Ivar Farup, Universität Giøvik, Norwegen
- Vertalerbouw von Theo Ruys, Universität Twente, Niederlande



^{1:} Diese Teile lehnen sich an an die Veranstaltungen

Aufbau der Veranstaltung 2



Weiterführende Themen

- Verwendung von Front-End-Generatoren (ca. 2-3 Wochen)
- Java Virtuelle Maschine (ca. 1-2 Wochen)





Syntax



Syntax oder Grammatik



Beschreibt die Satzstruktur von korrekten Programmen

- n := n + 1; Syntaktisch korrektes Statement in Triangle
- "Ein Kreis hat zwei Ecken."Syntaktisch korrekte Aussage in Deutsch



Kontextuelle Einschränkungen



Dazu gehören Regeln für den Geltungsbereich (*scope*) und den Typ von Aussagen.

- n muß bei Auftreten des Statements passend deklariert sein.
- Kreise haben im allgemeinen keine Ecken. Hier passen die Typen offenbar nicht.



Semantik



Die Bedeutung einer Anweisung/Aussage in einer Sprache. Wird bei Programmiersprachen häufig beschrieben . . .

Operationell Welche Schritte laufen ab, wenn das Programm gestartet wird?

Denotational Abbildung von Eingaben auf Ausgaben



Art der Spezifikation



- Für alle drei Teile
 - 1. Syntax
 - Kontextuelle Einschränkungen
 - Semantik
- ... gibt es jeweils zwei Spezifikationsarten
 - Formal
 - Informal

Triangle-Spezifikation

- Formale Syntax (reguläre Ausdrücke, EBNF)
- Informale kontextuelle Einschränkungen
- Informale Semantik



Syntax



Eine Sprache ist eine Menge von Zeichenketten aus einem Alphabet

- Wie diese Menge angeben?
- Bei endlichen Sprachen: Einfach Elemente aufzählen
- Geht nicht bei unendlichen Sprachen
- Einige mögliche Vorgehensweisen
 - 1. Mathematische Mengennotation
 - Reguläre Ausdrücke
 - 3. Kontextfreie Grammatik



Syntax durch Mengenbeschreibung



Beispiele für die beschriebenen Zeichenketten

- $L = \{a, b, c\}$ beschreibt a, b, c
- $L = \{\mathbf{x}^n | n > 0\}$ beschreibt $\mathbf{x}, \mathbf{xx}, \mathbf{xxx}, \dots$
- $L = \{\mathbf{x}^n \mathbf{y}^m | n > 0, m > 0\}$ beschreibt **xxy**, **xyy**, **xxxyy**, . . .
- $L = \{ \mathbf{x}^n \mathbf{y}^n | n > 0 \}$ beschreibt $\mathbf{x}\mathbf{y}, \mathbf{x}\mathbf{x}\mathbf{y}\mathbf{y}, \dots$, aber z.B. nicht $\mathbf{x}\mathbf{x}\mathbf{y}$

Offensichtlich keine sonderlich nützliche und gut zu handhabende Spezifikationsform für komplexere Sprachen.



Reguläre Ausdrücke (REs)



Erweitere Zeichenketten aus dem Alphabet um Operatoren

- zeigt Alternativen an
- * zeigt Null oder mehr Vorkommen des vorangehenden Zeichens an
- ε ist die leere Zeichenkette
- (...) erlauben die Gruppierung von Teilausdrücken durch Klammerung

Beispiele

- L = a|b|c ergibt a, b, c
- L = ab* ergibt a, ab, abb, ...
- L = (ab)* ergibt die leere Zeichenkette ε , ab, abab, ababab, . . .
- $L = a(b|\varepsilon)$ ergibt a oder ab



Mächtigkeit von REs?



Kann man die Menge aller regulären Ausdrücke selber durch einen regulären Ausdruck beschreiben?

Nein! REs sind daher ungeeignet zur Beschreibung der Syntax komplexer Programmiersprachen

... also Weitersuchen nach geeigneter Beschreibungsform für Syntax

Aber: REs sind trotzdem innerhalb eines Compilers nützlich (siehe PLPJ Kapitel 4, Scanner).



Kontextfreie Grammatiken (CFGs) 1



Eine kontextfreie Grammatik besteht aus

- ► Einer Menge von Terminalsymbolen *T* aus Alphabet
- Einer Menge von Nicht-Terminalsymbolen N
- ightharpoonup Einem Startsymbol $S \in N$
- Einer Menge von Produktionen P
 - Beschreiben, wie Nicht-Terminalsymbole aus Terminalsymbolen zusammengesetzt sind.



Kontextfreie Grammatiken (CFGs) 2



Produktionen in Backus-Naur-Form (BNF)

Nicht-Terminal ::= Zeichenkette aus Terminal und Nicht-Terminalsymbolen

Produktionen in Extended BNF (EBNF)

Nicht-Terminal ::= RE aus Terminal und Nicht-Terminalsymbolen



BNF Beispiel 1



$$T = \{x, y\}, N = \{S, B\}, S = S, P = \{A, B\}, S = S, P = \{A, B\}, S = S, P = \{A, B\}, P = \{A,$$

$$S ::= xS \tag{1}$$

$$S ::= x \tag{3}$$

$$B ::= yB$$
 (4)

$$\mathbf{B} ::= \mathbf{y}$$
 (5)

Ist die Zeichenkette xxyyy Element der durch T, N, S, P beschriebenen Sprache?

$$extsf{S}
ightarrow extsf{xxS}
ightarrow extsf{xxyB}
ightarrow extsf{xxyyB}
ightarrow extsf{xxyyy}$$

⇒Ja, da sie sich aus S herleiten läßt.



(2)

BNF Beispiel 2



$$T = \{x, y\}, N = \{S, B\}, S = S, P = \{A, B\}, S = S, P = \{A, B\}, S = S, P = \{A, B\}, P = \{A,$$

$$S ::= xS$$
 (6)

$$S ::= x \tag{8}$$

$$\mathbf{B} ::= \mathbf{yB} \tag{9}$$

$$\mathbf{B} ::= \mathbf{y}$$
 (10)

Ist die Zeichenkette xy Element der durch T, N, S, P beschriebenen Sprache?

$$\mathbf{S} \rightarrow \mathbf{xS} \rightarrow \mathbf{xyB} \rightarrow \mathbf{?}$$

⇒Nein, da sie sich nicht aus S herleiten läßt.



(7)

Mehrdeutigkeit in BNF



Gegeben seien die Produktionen:

$$S ::= S+S$$
 (11)

$$\mathbf{S} ::= \mathbf{x} \tag{12}$$

Wie läßt sich die Zeichenkette **x+x+x** herleiten?

$$\textbf{S} \rightarrow \textbf{S+S} \rightarrow \textbf{x+S} \rightarrow \textbf{x+S+S} \rightarrow \textbf{x+x+S} \rightarrow \textbf{x+x+x}$$

Aber auch anders:

$$extsf{S} o extsf{S+S} o extsf{S+x} o extsf{S+x} o extsf{S+x+x} o extsf{x+x+x}$$



Eindeutige CFG



Für sinnvolle praktische Anwendungen müssen CFGs eindeutig sein.

Eindeutige Produktionen für die gleiche CFG:

$$S ::= x+S \tag{13}$$

$$S ::= x \tag{14}$$





(Mini-) Triangle



(Mini-) Triangle



- Pascal-artige Sprache als Anschauungsobjekt
- Compiler-Quellcode auf Web-Page
- In der Vorlesung: Mini-Triangle
 - Weiter vereinfachte Version
 - Z.B. keine Definition von Unterfunktionen





```
Program ::= single-Command
single-Command ::= empty

| V-name := Expression
| Identifier ( Expression )
| if Expression then single-Command
else single-Command
| while Expression do single-Command
| let Declaration in single-Command
| begin Command end
Command ::= single-Command
| Command ; single-Command
```





```
Expression
::= primary-Expression
| Expression Operator primary-Expression
primary-Expression
::= Integer-Literal
| V-name
| Operator primary-Expression
| ( Expression )
V-name ::= Identifier
Identifier ::= Letter
| Identifier Letter
| Identifier Digit
Integer-Literal ::= Digit
| Integer-Literal Digit
Operator ::= + | - | * | / | < | > | =
```





```
Declaration
    ::= single-Declaration
    | Declaration ; single-Declaration
    single-Declaration
    ::= const Identifier ~ Expression
    | var Identifier : Type-denoter
Type-denoter ::= Identifier
```





```
Comment ::= ! CommentLine eol
CommentLine ::= Graphic CommentLine
Graphic ::= any printable character or space
Digit ::= 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9
```



Terminologie



Phrase Von einem gegebenen Nicht-Terminalsymbol herleitbare Kette von Terminalsymbolen.

Z.B. Expression-Phrase, Command-Phrase . . .

Satz S-Phrase, wobei S das Startsymbol der CFG ist

Beispiel:

- Das gesamte Program ist ein Satz der CFG
- Zeile 2 ist eine single-Declaration-Phrase
- Zeile 4 ist eine single-Command-Phrase



Syntaxbäume



Ein Syntaxbaum ist ein geordneter, markierter Baum bei dem

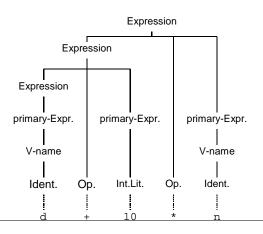
- ▶ ... die Blätter mit Terminalsymbolen markiert sind
- ...die inneren Knoten mit Nicht-Terminalsymbolen markiert sind
- ▶ ... jeder innere Knoten **N** (von links nach rechts) die Kinder $\mathbf{X}_1, ..., \mathbf{X}_n$ hat, entsprechend der Produktion $\mathbf{N} := \mathbf{X}_1 ... \mathbf{X}_n$

Ein N-Baum ist ein Baum mit einem N Nicht-Terminalsymbol am Wurzelknoten.



Expression-Baum für d + 10 * n



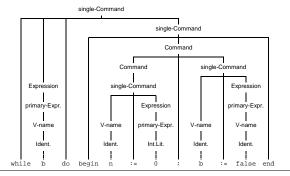




single-Command-Baum



```
while b do begin
  n := 0;
  b := false
end
```





Konkrete und abstrakte Syntax



- Grammatik spezifiziert präzise syntaktische Details
 - ▶ do. :=....
- ⇒Konkrete Syntax, wichtig für das Verfassen korrekter Programme
 - Konkrete Syntax hat aber keinen Einfluß auf Semantik der Programme
 - V = E
 - ▶ V := E
 - set V = E
 - assign E to V
 - ightharpoonup V \leftarrow E
 - ... können alle das gleiche bedeuten: Eine Zuweisung von E nach V
- ⇒Für weitere Verarbeitung Darstellung vereinfachen!



Abstrakte Syntax 1



- Modelliert nur essentielle Information
- Idee: Orientierung an der Subphrasen-Struktur der Produktionen
- Beispiel: V-name := Expression hat zwei Subphrasen
 - 1. V-name
 - Expression



Abstrakte Syntax 2



- Schlüsselworte, Begrenzer wie do, := sind irrelevant
- Unterscheidungen zwischen
 - Command und single-Command
 - Declaration und single-Declaration
 - Expression und primary-Expression
- sind nur für das Erkennen des Programmes relevant, nicht zur Darstellung seiner Semantik.
- →Alle dafür unwichtigen Details weglassen!



Auszug aus der abstrakten Syntax 1





Auszug aus der abstrakten Syntax 2



```
Expression
```

::= Integer-Literal

I V-name

| Operator Expression

| Expression Op Expression

V-name::= Identifier

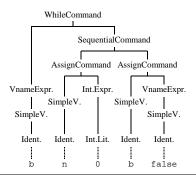
IntegerExp VnameExp UnaryExp BinaryExp SimpleVName



Beispiel abstrakte Syntax



```
while b do begin
  n := 0;
  b := false
end
```





AST als Zwischendarstellung 1



- AST ist eine weit verbreitete Form der IR
- High-level IR
- Sehr nah an der Eingabesprache
- Gut geeignet für weitreichende Analysen und Transformationen
 - Unabhängig von Architektur der Zielmaschine
 - Verschieben von Anweisungen
 - Änderungen der Programmstruktur



AST als Zwischendarstellung 2



Schlechter geeignet für maschinennahe Analysen und Transformationen

- Ausnutzung von Maschinenregistern
- Ausnutzung von speziellen Maschinenbefehlsfolgen
- ⇒Hier: Konzentration auf maschinenunabhängige Ebene
 - (D)AST ist Hauptrepräsentation
 - Für einzelne Bearbeitungsschritte: Andere IRs





Kontextuelle Einschränkungen



Kontextuelle Einschränkungen: Geltungsbereiche



Syntaktische Korrektheit reicht nicht aus für sinnvolle Übersetzung

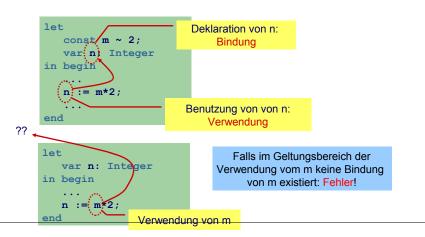
Geltungsbereiche (Scope)

- Betreffen Sichtbarkeit von Bezeichern
- Jeder verwendete Bezeichner muss vorher deklariert werden
 - ... nicht bei allen Programmiersprachen
- Deklaration ist sog. bindendes Auftreten des Bezeichners
- Benutzung ist sog. verwendendes Auftreten des Bezeichners
- Aufgabe: Bringe jede Verwendung mit genau der einen passenden Bindung in Zusammenhang



Beispiele Geltungsbereiche







Kontextuelle Einschränkungen: Typen



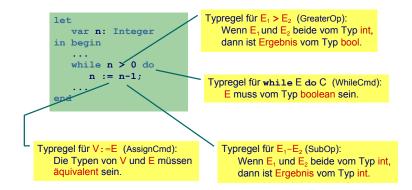
Typen

- Jeder Wert hat einen Typ
- Jede Operation
 - ...hat Anforderungen an die Typen der Operanden
 - ...hat Regeln für den Typ des Ergebnisses
- ... auch nicht bei allen Programmiersprachen.
 - ▶ Hier: statische Typisierung (zur Compile-Zeit)
 - Alternativ: dynamische Typisierung (zur Laufzeit)



Beispiele Typen









Semantik



Semantik 1



Semantik beschreibt die Bedeutung eines Programmes zur Ausführungszeit. Allgemeine Terminologie:

Anweisungen

- ... werden ausgeführt. Mögliche Seiteneffekte:
 - Ändern der Werte von Variablen
 - Ein-/Ausgabeoperationen



Semantik 2



Ausdrücke

- ... werden ausgewertet (evaluiert), um ein Ergebnis zu erhalten.
 - Die Evaluation kann in einigen Sprachen auch Seiteneffekte haben.

Deklarationen

- ... werden elaboriert um eine Bindung vorzunehmen. Mögliche Seiteneffekte:
 - Allokieren von Speicherplatz
 - Initialisieren von Speicherplatz



Beispiele Semantik von (Mini)Triangle 1



Die Beschreibung orientiert sich am AST.

AssignCmd v := E

- 1. Der Ausdruck E wird evaluiert um einen Wert v zu erhalten
- 2. v wird an die Variable v zugewiesen

BinaryExp \mathbf{E}_1 op \mathbf{E}_2

- 1. Der Ausdruck \mathbf{E}_1 wird evaluiert um einen Wert v_1 zu erhalten
- 2. Der Ausdruck \mathbf{E}_2 wird evaluiert um einen Wert v_2 zu erhalten
- Die Werte v₁ und v₂ werden mit dem Operator op zu einem Wert v₃ verknüpft.
- 4. *v*₃ ist das Ergebnis der BinaryExp



Beispiele Semantik von (Mini)Triangle 2



Declaration var I : T

- 1. Der Bezeichner I wird an eine Variable vom Typ T gebunden
- Es wird ein für T passender Speicherbereich bereitgestellt
- Der Speicherbereich ist nicht initialisiert
- Der Geltungsbereich für I ist der eingeschlossene Block (LetCmd)
- 5. Am Ende des Blockes wird die Bindung aufgehoben
- 6. ... und der Speicherbereich wieder freigegeben



Triangle



- In Vorlesung: Mini-Triangle
 - Stark vereinfacht
 - Z.B. Keine Unterprogramme (Prozeduren/Funktionen)
- Im praktischen Teil: Triangle
 - Pascal-artige Sprache
 - Arrays, Records, Prozeduren, Funktionen
 - Parameterübergabe durch Wert oder Referenz
 - Prozeduren/Funktionen als Parameter erlaubt
 - Ausdrücke haben keine Seiteneffekte
- Beschreibung in PLPJ, Anhang B



Zusammenfassung



- Überblick
- Organisation
- Material in PLPJ, Kapitel 1
 - Syntax (konkrete und abstrakte)
 - Kontextuelle Einschränkungen
 - Semantik
 - AST als IR
 - (Mini-)Triangle

